

# 프로젝트 #1 결과 발표

2022. 4. 13

충북대학교 산업인공지능학과

[21-5조] 방창현, 정원용

# 수행방법 및 기여도

## 수행방법

- 같은 회사에 재직중이어서 수시로 얘기하여 업무 분장 및 수행 진행
- 방창현 : 현업에서 개발 보다는 프로젝트 관리 업무 수행중이며 관련 경험에 맞추어 코딩보다는 데이터 셋 관련 업무 중심으로 진행함.
- 정원용 : 현업에서 개발에 관한 설계 및 개발 업무를 진행하고 있어서 코딩/학습 관련 업무 중심으로 진행함.

## 업무분장 및 기여도

이름	비중	수행내용	비고
방창현	50%	<ul style="list-style-type: none"><li>• 데이터 증량</li><li>• 주제발표</li></ul>	
정원용	50%	<ul style="list-style-type: none"><li>• 코딩/학습</li><li>• 결과발표</li></ul>	

- 비중은 총합이 100%일 것

# 데이터셋


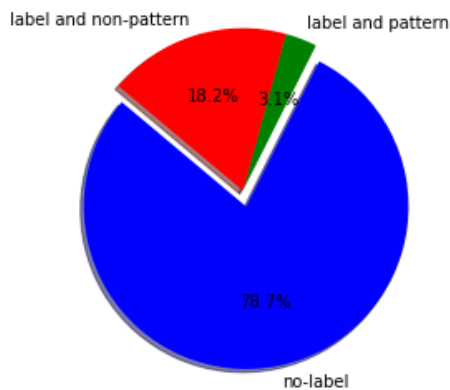
## Data augmentation/전처리

데이터 : 'LSWMD.pkl' (kaggle에서 다운로드)

실제 제조에서 46,393개 로트에서 수집된 811,457개의 웨이퍼 맵에 대한 데이터

이 데이터셋의 모든 결함 유형에 대한 종류 :

Center, Donut, Edge-Loc, Edge-Ring, Loc, Random, Scratch, Near-full, none.




Total wafers = 811457  
With label = 172950  
Non label = 638507

With pattern = 25519  
Non pattern = 147431

# 데이터셋

## Data augmentation/전처리




Faulty case : ['none']

26 X 26

Center : 90  
Donut : 1  
Edge-Loc : 296  
Edge-Ring : 31  
Loc : 297  
Near-full : 16  
Random : 74  
Scratch : 72  
none : 13489  
new\_x.shape : (14366, 26, 26, 3)

### Encoder

epoch= 30  
batch\_size= 1024  
padding= 'same'  
activation= 'sigmoid'  
optimizer = 'Adam'  
loss = 'mse'



### 학습절차

1. 원래 결함 웨이퍼 인코딩
2. 인코딩된 잠재적 결함 웨이퍼 벡터에 노이즈를 추가.
3. 모든 결함 케이스에 대한 보강
4. 데이터 증량
  - 웨이퍼의 총 개수가 2000개가 될 때까지 웨이퍼를 만듦
  - 동일한 길이의 레이블 벡터를 만듦.

### Decoder

epoch= 30  
batch\_size= 1024  
padding= 'same'  
activation= 'relu', 'sigmoid'  
optimizer = 'Adam'  
loss = 'mse'

# 데이터셋

## Data augmentation/전처리

### 학습결과


After Generate new\_x shape : (30707, 26, 26, 3),  
new\_y shape : (30707, 1)

Center : 2160  
Donut : 2002  
Edge-Loc : 2368  
Edge-Ring : 2046  
Loc : 2376  
Near-full : 2032  
Random : 2146  
Scratch : 2088  
none : 13489



After Delete "none" class new\_x shape : (19707, 26, 26, 3),  
new\_y shape : (19707, 1)

Center : 2160  
Donut : 2002  
Edge-Loc : 2368  
Edge-Ring : 2046  
Loc : 2376  
Near-full : 2032  
Random : 2146  
Scratch : 2088  
none : 2489



### Train

x : (**12730**, 26, 26, 3),  
y : (12730, 9)

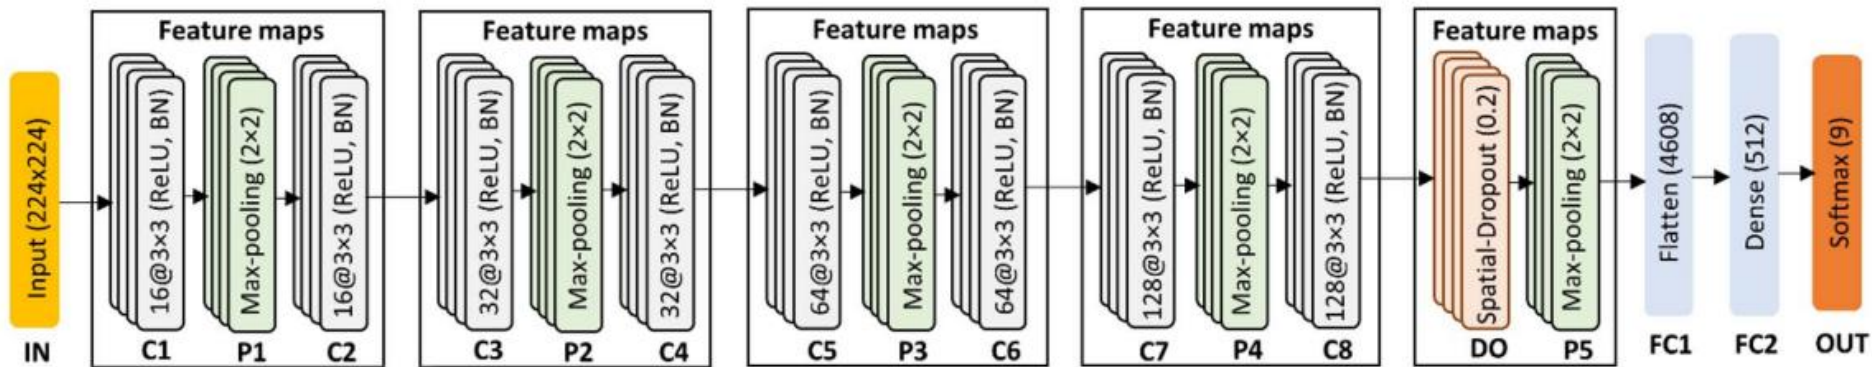
### Test

x: (**6270**, 26, 26, 3),  
y : (6270, 9)

# CNN 구조

## CNN 구조

- 그림/표/모델정보(실행화면)로 표현 (논문과 동일? 다르면 어떤 부분이 다른지 등)



\*Note: IN denotes input layer; C convolution layer; P pooling layer; DO dropout layer; FC fully connected layer; OUT output layer; and BN batch normalization

C2	Convolution2	16	111×111	3×3	Yes	ReLU
C3	Convolution3	32	111×111	3×3	Yes	ReLU
P2	Max Pooling2	32	55×55	2×2	No	-
C4	Convolution4	32	55×55	3×3	Yes	ReLU
C5	Convolution5	64	55×55	3×3	Yes	ReLU
P3	Max Pooling3	64	27×27	2×2	No	-
C6	Convolution6	64	27×27	3×3	Yes	ReLU
C7	Convolution7	128	27×27	3×3	Yes	ReLU
P4	Max Pooling4	128	13×13	2×2	No	-
C8	Convolution8	128	13×13	3×3	Yes	ReLU
P5	Max Pooling5	128	6×6	2×2	No	-
FC1	Fully-Connected1	1	4608	-	-	ReLU
FC2	Fully Connected2	1	512	-	-	ReLU
OUT	Output	1	9	-	-	Softmax

## 과적합을 방지하기 위한 규제화(regulation)

- Batch Normalization(정규화)
- Spatial Dropout = 0.2

# CNN 구조

## 주요 코드 및 실행 결과

- 딥러닝 프레임워크(tensorflow, keras)

```
# Encoder
input_shape = (26, 26, 3)
input_tensor = Input(input_shape)
encode = layers.Conv2D(64, (3,3), padding='same', activation='relu')(input_tensor)

latent_vector = layers.MaxPool2D()(encode)

# Decoder
decode_layer_1 = layers.Conv2DTranspose(64, (3,3), padding='same', activation='relu')
decode_layer_2 = layers.UpSampling2D()
output_tensor = layers.Conv2DTranspose(3, (3,3), padding='same', activation='sigmoid')

# connect decoder layers
decode = decode_layer_1(latent_vector)
decode = decode_layer_2(decode)

ae = models.Model(input_tensor, output_tensor(decode))
ae.compile(optimizer = 'Adam',
            loss = 'mse',
            )
```

```
epoch=30
batch_size=1024
```

```
# start train
ae.fit(new_x, new_x,
        batch_size=batch_size,
        epochs=epoch,
        verbose=2)
```

# CNN 구조

## 주요 코드 및 실행 결과

- 활성화 함수 : *sigmoid*, optimizer : *Adam*, loss 함수 : *categorical\_crossentropy*

```
def create_model():
    input_shape = (26, 26, 3)
    input_tensor = Input(input_shape)

    conv_1 = layers.Conv2D(16, (3,3), activation='sigmoid', padding='same')(input_tensor)
    conv_2 = layers.Conv2D(64, (3,3), activation='sigmoid', padding='same')(conv_1)
    conv_3 = layers.Conv2D(128, (3,3), activation='sigmoid', padding='same')(conv_2)

    flat = layers.Flatten()(conv_3)

    dense_1 = layers.Dense(512, activation='sigmoid')(flat)
    dense_2 = layers.Dense(128, activation='sigmoid')(dense_1)
    output_tensor = layers.Dense(9, activation='sigmoid')(dense_2)

    model = models.Model(input_tensor, output_tensor)
    model.compile(optimizer='Adam',
                  loss='categorical_crossentropy',
                  metrics=['accuracy'])

    return model
```



# 학습 방법

## 딥러닝 학습 조건

- (HW) PC 사양, 학습시간

CPU : Intel CPU i5-1135G7 @ 2.40GHz



RAM : 16GB

GPU : 내장 그래픽카드(Iris Xe)

- 하이퍼파라미터 :  $epoch=30$ ,  $batch\ size=1024$ ,  
 $optimizer = 'Adam'$ ,  $loss\ 함수 = 'categorical\_crossentropy'$

소요시간 : 약 2시간



추이 그래프





# CNN 구조

- Kaggle 참고 사이트 결과

(<https://www.kaggle.com/code/shawon10/wafer-defect-classification-by-deep-learning/notebook>)




- 구동 결과



# 결과 및 토의

## 분류 성능

- *Confusion matrix* 및 *평가지표* (논문 결과와 비교 : 우수/동일/미달... 그 이유는?)
- 구체적인 분석



논문의 성과와 비교

OVERALL PERFORMANCE COMPARISON OF VARIOUS CLASSIFIERS (%)

Classifier	Training Acc	Validation Acc	Testing Acc	Precision	Recall	F1-Score
CNN-WDI	98.9	<b>96.4</b>	<b>96.2</b>	<b>96.2</b>	<b>96.2</b>	<b>96.2</b>
CNN-D	97.6	95.5	95.2	95.2	95.2	95.2
CNN-BN	<b>99.4</b>	95.6	95.6	95.6	95.6	95.6
CNN-SD	98.6	94.7	94.8	94.8	94.8	94.8
VGG-16	82.3	80.0	80.1	80.3	80.1	79.9
ANN	95.9	95.9	72.0	95.2	95.9	95.4
SVM	91.3	91.0	32.6	87.5	91.0	88.0

Note: Boldface numbers denote the highest values of different performance measures and Acc accuracy

# 결과 및 토의

---

## 토의 및 개선점

- kaggle의 예제를 이해하기도 벅찬 상태
- 현업의 업무가 우선이고 야근이 많다 보니 주말에 시간내서 하고는 있지만 따라가기 쉽지 않은 상태임.

**감사합니다**